当代人工智能 Lab1

姓名：李昕芮　　学号：10243330406

Github 仓库：*https://github.com/water0417/CAI_lab1_lxr.git*

1.训练集、验证集与测试集

1.1 数据划分：对于训练集和验证集采用本实验采用 5 折重复 5 次，共 25 组估计，以均值±标准差报告结果。

```
RepeatedStratifiedKFold(n_splits=n_splits, n_repeats=n_repeats,random_state=SEED)
```

选择依据：通过固定同一分类器（LinearSVC），仅改变随机种子开展对照，对比波动情况来评估数据划分随机性对性能估计的干扰，。单次划分性能波动极差达 0.0207，易造成对比结论失真。5 折交叉验证显著降低估计波动。

划分方案	估计值个数	均值	标准差	极差
Holdout 80/20	10	0.9100	0.0070	0.0207
5 折 CV	6	0.9154	0.0025	0.0073

1.2 划分有效性验证

各折验证集样本量稳定在 1473- 1474 条，类别占比相对全集的最大偏差仅为 0.0006，分层采样生效。

1.3 隔离测试集

采用 Pipeline 封装 TF-IDF 与分类器，数据集划分优先于特征拟合：TF-IDF 仅使用训练集拟合；数据增强仅作用于训练样本，测试集文件做隔离，读取前进行 SHA256 指纹字节校验，运行日志记录对应数据指纹，可自证测试集未使用。

2.数据预处理与数据增强

	数据预处理	数据增强
实验	13 组清洗配置，在 LinearSVC+25 折重复 CV 下做消融，以原始文本为基线，配对 t 检验判断统计显著性。	三轮实验，测试结构扰动与 LSA 语义近邻替换增强（仅训练集增强），采用配对检验评估效果与标签稳定性。
发现	实验结果详见 figs/fig3_cleaning_forest.png	详见 figs/term/term_13_augment_robust.png、term_14_augment_label_integrity.png、term_15_semantic_aug.png
结论	清洗并非越多越好，通用清洗流程不能直接套用，需保留主题、引用等有效信息，针对性去除有害捷径特征。	在本数据集、TF-IDF+LinearSVC 的设定下，数据增强增益较小，受限于词袋表征与 LSA 近邻质量。

3.调参数

3.1 TF-IDF 参数调优

固定预处理与 LinearSVC 模型开展单参数敏感性扫描，先每次改动一个参数，再补充参数组合实验，考察参数交互。

max_features	**20000**	**+0.0204**	**显著**
max_features	**2000**	**-0.0423**	**显著**
max_features	**(1,2)**	**-0.0135**	**显著**
sublinear_tf	**True**	**-0.0028**	**显著**
min_df` 2/5/10、`max_df` 0.5/0.9		**−0.0004~+0.0007**	**不显著**

经组合实验发现存在参数交互效应，详见 figs/term/term_17_tfidf_combo.png。

本实验最终 TF-IDF 配置为 max_features=50000, sublinear_tf=True, ngram_range=(1,1)，其余参数保持默认。

3.2 模型超参调优

LinearSVC					
C	0.01	0.1	1.0	10.0	100.0
Macro-F1	0.9060	0.9324	0.9434	0.9428	0.9413

LogisticRegression					
C	0.01	0.1	1.0	10.0	100.0
L2	0.8727	0.9019	0.9267	0.9399	0.9419
L1	0.0184	0.5562	0.8565	0.9118	0.9151
L2-L1	-0.8543	-0.3457	-0.0702	-0.0281	-0.0268

NaiveBayes					
alpha	0.01	0.05	0.1	0.2	1.0
Macro-F1	0.9353	0.9390	0.9391	0.9365	0.9187
泛化间隙	0.0618	0.0557	0.0538	0.0532	0.0565
Δ	+0.0166	+0.0203	+0.0204	+0.0178	—

LogisticRegression				
\	(50,)	(100,)	(200,)	(100,50)
1e-4	0.9411	0.9450	0.9425	0.9434
1e-3	0.9437	0.9455	0.9426	0.9424
1e-2	0.9428	0.9445	0.9405	0.9414

4.实验结果

4.1 四模型主结果

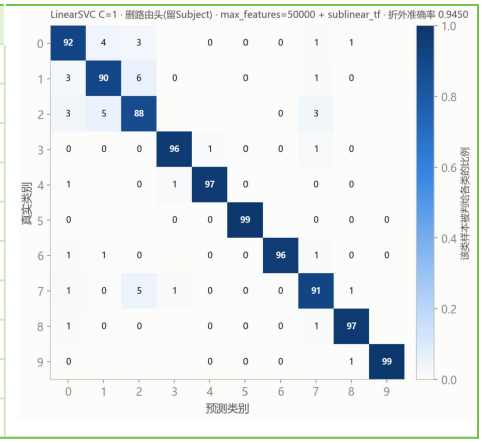
将四个模型调优后得到 50000 维下的完整评估指标（具体分析以及 5000 维对比看板请见 figs/dashboard.html）：

模型	NaiveBayes	LogisticRegression	LinearSVC	MLP
超参	α=0.1	C=100	C=1	(100,)、α=1e-3
Accuracy	0.9388 ± 0.0053	0.9403 ± 0.0068	**0.9432 ± 0.0063**	0.9442 ± 0.0064
MacroF1 均值	0.939109	0.940505	**0.943393**	0.944500
Macro-F1	0.9391 ± 0.0053	0.9405 ± 0.0068	**0.9434 ± 0.0062**	0.9445 ± 0.0060
Weighted-F1	0.9391 ± 0.0053	0.9405 ± 0.0068	**0.9433 ± 0.0063**	0.9444 ± 0.0063
训练-MacroF1	0.9929 ± 0.0013	0.9998 ± 0.0008	**0.9996 ± 0.0002**	0.9939 ± 0.0019
泛化间隙	0.0565	0.0593	**0.0562**	0.0493
单折耗时(s)	0.02	4.5	**0.51**	195.2

4.2 最优模型与错误分析

本章针对最优模型 LinearSVC (C=1) 开展错误分析，定位模型失效模式，判断性能瓶颈来自模型本身还是特征表示。

类别	TF- IDF 关键词	F1	是否易混淆
PC 硬件	drive,card,ide,scsi,controller	0.8685	是
Windows/DOS	windows,dos,microsoft,ms	0.8999	是
图形 / 3D	graphics,image,3d,files	0.9065	是
电子电路	circuit,power,used	0.9096	是
汽车	car,cars,engine	0.9669	否
医学	doctor,medical,pitt	0.9751	否
加密 / 密码学	clipper,key,encryption,escrow	0.9755	否
摩托车	bike,ride,riding	0.9765	否
棒球	baseball,game,team,players	0.9833	否
中东政治	israel,jews,arab,jewish,turkish	0.9907	否



4 个计算机领域类别共享大量通用技术词汇，话题边界模糊，而汽车、政治等类别特征词几乎无重叠，容易被线性模型区分。线性模型基于词汇重叠完成分类，推测性能瓶颈来自词袋特征本身局限，后续提升尝试优先改进特征表示。

5.思考

5.1 为什么在这个数据集上，SVM 和逻辑回归的表现通常很好?

在 50000 维下实验总分数中 MLP≈SVM>LR>NB，虽然 MLP 微高，但结合泛化性能评判可分性后认为 SVM 和逻辑回归表现更好。随维度升高，泛化性能提升，L1 正则性能崩溃而 L2 良好，信息分散在弱特征。结合错误模式与较小泛化间隙，证实高维稀疏词袋下数据近似线性可分，线性模型与数据结构匹配，逼近该表示的性能上限，因此表现优异。

5.2 MLP 模型的性能是否可以通过调整网络结构或训练参数来进一步提升？是否存在过拟合的风险?

通过网格搜索、迭代控制、多规模学习曲线分析实验发现，MLP 从高维特征中获益更多，但尝试加宽、加深网络、提高迭代轮次均未提升效果，任务近似线性可分，现有网络容量已经充足，多余容量仅引入方差。MLP 的过拟合与数据量强相关：小样本下过拟合严重，全量样本时泛化间隙最小。sklearn MLP 将稀疏输入稠密化，带来时间与内存开销。

5.3 除了 TF-IDF，还有哪些文本表示方法？（例如：词袋模型、Word2Vec、BERT 等）

表示方法	特点	相比 TF-IDF
TF-IDF（本实验）	稀疏可解释，无需训练	高维，无语义，无法处理同义/多义
词袋 / One- hot	统计词频，无权重	丢失 IDF 判别能力，效果较差
Word2Vec/GloVe	静态稠密词向量，文档取均值	捕捉同义，不能处理多义，丢失词序
LSA/LDA 主题模型	基于潜在主题降维	缓解语义相近词汇混淆，需调主题数
BERT 预训练	上下文感知，支持多义理解	性能上限高，模型大、速度慢，需 GPU

6.创新点与局限性

创新点:1.配对 t 检验甄别真实差异 2.随机标签对照校验逻辑 3.SHA256 防测试集泄露 4.对照实验排除备选假设 5.多视角消融定位收益 6.参数组合挖掘交互效应

局限性：·1.数据集含近重复样本 2.类别标签为反推得到 3.MLP 调参搜索**时间太长没跑完**4.结论迁移性未验证